

Projeto 2 – Métodos Numéricos

Modelagem de Tópicos em Notícias Utilizando TF-IDF e Fatoração Matricial Não Negativa

Alunos: Guilherme José Mendes Jerônimo (202321250017)
William de Sousa Costa (202321250008)

Professor: Paulo Ribeiro

Semestre: 2025.1

Entrega: 22 de junho de 2026

Sumário

1	Descrição do Problema	2
1.1	Contexto e Motivação	2
1.2	Formulação Matemática	2
1.3	Aplicações Associadas	2
2	Métodos Aplicados à Solução	4
2.1	Método 1: TF-IDF (Term Frequency – Inverse Document Frequency) . .	4
2.1.1	Descrição Geral	4
2.1.2	Algoritmo	4
2.1.3	Propriedades e Complexidade	4
2.1.4	Justificativa para o Problema	4
2.2	Método 2: Fatoração Matricial Não Negativa (NMF)	4
2.2.1	Descrição Geral	4
2.2.2	Algoritmo	5
2.2.3	Propriedades e Complexidade	5
2.2.4	Justificativa para o Problema	5
3	Implementação	6
3.1	Ambiente e Dependências	6
3.2	Etapa 1: Carregamento e Pré-processamento dos Dados	6
3.3	Etapa 2: Construção da Matriz TF-IDF e Extração do Modelo NMF . .	6
3.4	Etapa 3: Visualização e Avaliação das Palavras-Chave	7
4	Conclusão	8

1. Descrição do Problema

1.1. Contexto e Motivação

O crescimento exponencial da quantidade de documentos digitais tornou inviável a classificação manual de grandes coleções textuais. Portais de notícias, redes sociais e repositórios corporativos produzem milhares de documentos diariamente, exigindo técnicas automáticas para organização e descoberta de conhecimento.

Uma das abordagens mais utilizadas para esse problema é a **Modelagem de Tópicos (Topic Modeling)**, cujo objetivo é identificar temas latentes presentes em um conjunto de documentos sem a necessidade de rótulos previamente definidos.

Neste projeto foi utilizada uma base de notícias da BBC News contendo documentos de diferentes áreas, como política, negócios, esportes, entretenimento e tecnologia. O objetivo consiste em descobrir automaticamente esses agrupamentos temáticos por meio de técnicas de Processamento de Linguagem Natural (PLN) e fatoração matricial.

1.2. Formulação Matemática

Após o pré-processamento textual, cada documento é convertido para uma representação numérica utilizando a técnica TF-IDF.

A matriz documento-termo é definida formalmente por:

$$\mathbf{V} \in \mathbb{R}^{m \times n} \quad (1)$$

onde:

- m representa o número de documentos;
- n representa o número de termos do vocabulário.

A modelagem de tópicos é realizada através da **Fatoração Matricial Não Negativa (NMF)**, que procura decompor a matriz original em duas matrizes menores com restrição de não-negatividade:

$$\mathbf{V} \approx \mathbf{WH} \quad (2)$$

onde $\mathbf{W} \in \mathbb{R}^{m \times k}$ representa a distribuição de tópicos em cada documento e $\mathbf{H} \in \mathbb{R}^{k \times n}$ representa a relevância de cada palavra para cada tópico. O parâmetro k corresponde ao número de tópicos desejados.

1.3. Aplicações Associadas

- Organização automática de notícias;
- Sistemas de recomendação de conteúdo;
- Análise de tendências em redes sociais;
- Descoberta de conhecimento em bases documentais;

- Recuperação de informação direcionada.

Nota sobre os dados

Foi utilizada uma coleção de notícias da BBC News contendo textos em língua inglesa. Os documentos foram submetidos a etapas de limpeza, remoção de *stopwords* e vetorização TF-IDF antes da aplicação do modelo NMF.

Modelos baseados em fatoração de matrizes não negativas são amplamente discutidos na literatura para a extração de estruturas semânticas latentes (**datacamp_topic_modeling**).

2. Métodos Aplicados à Solução

2.1. Método 1: TF-IDF (Term Frequency – Inverse Document Frequency)

2.1.1. Descrição Geral

O algoritmo TF-IDF transforma documentos textuais em vetores numéricos. A frequência TF mede a importância de uma palavra dentro de um documento, enquanto o fator IDF reduz a relevância de palavras excessivamente comuns ao longo de todo o *corpus*.

2.1.2. Algoritmo

Algorithm 1 Vetorização TF-IDF

Require: Corpus de documentos limpos D , Vocabulário extraído T

Ensure: Matriz Termo-Documento $\mathbf{V}$

- 1: Calcular $TF(t, d)$ para cada termo em cada documento
 - 2: Calcular $IDF(t) = \log\left(\frac{N}{df(t)}\right)$
 - 3: Multiplicar os valores obtidos: $TFIDF(t, d) = TF(t, d) \times IDF(t)$ **return** Matriz de características $\mathbf{V}$
-

2.1.3. Propriedades e Complexidade

Propriedade	Valor
Complexidade temporal	$\mathcal{O}(m \times \text{comprimento médio dos documentos})$
Complexidade espacial	$\mathcal{O}(m \times n)$ (geralmente esparsa)
Convergência	Direta (Passo único)

2.1.4. Justificativa para o Problema

A vetorização via TF-IDF permite penalizar termos muito frequentes no idioma inglês que não agregam valor discriminatório entre os tópicos (como conectivos adicionais), realçando palavras-chave específicas de cada domínio jornalístico.

2.2. Método 2: Fatoração Matricial Não Negativa (NMF)

2.2.1. Descrição Geral

A Fatoração Matricial Não Negativa é uma técnica de decomposição de matrizes amplamente utilizada em mineração de textos (**datacamp_topic_modeling**). Seu objetivo é aproximar a matriz documento-termo por duas matrizes não negativas menores, permitindo interpretar cada componente como um tópico latente (**nbis_nmf**).

2.2.2. Algoritmo

Algorithm 2 Fatoração Matricial Não Negativa (NMF)

Require: Matriz de entrada $\mathbf{V}$, Número de tópicos k

Ensure: Matrizes não-negativas $\mathbf{W}$ e $\mathbf{H}$

- 1: Inicializar $\mathbf{W} \geq 0$ e $\mathbf{H} \geq 0$ (e.g., via NNDSVD)
 - 2: **while** não atingir critério de parada / convergência **do**
 - 3: Atualizar $\mathbf{H}$ minimizando a função de custo (e.g., Frobenius)
 - 4: Atualizar $\mathbf{W}$ mantendo as restrições de não-negatividade
 - 5: **end while** **return** $\mathbf{W}, \mathbf{H}$
-

2.2.3. Propriedades e Complexidade

Propriedade	Valor
Complexidade temporal	$\mathcal{O}(mnk)$ por iteração
Complexidade espacial	$\mathcal{O}(mk + kn)$
Convergência	Iterativa (Local)

2.2.4. Justificativa para o Problema

A restrição de não-negatividade ($\mathbf{W} \geq 0$ e $\mathbf{H} \geq 0$) impossibilita a ocorrência de pesos negativos, o que favorece uma interpretação puramente aditiva das partes. Isso se adequa perfeitamente ao conceito de tópicos, onde documentos são vistos como combinações estritas de assuntos de forma interpretável.

3. Implementação

3.1. Ambiente e Dependências

A implementação foi realizada em Python 3.x utilizando o ecossistema científico padrão listado a seguir:

- pandas – manipulação e estruturação da base de dados
- numpy – operações algébricas matriciais de base
- nltk – suporte a funções de texto básico
- scikit-learn – extração de características (TF-IDF) e modelo NMF
- matplotlib – geração e plotagem dos gráficos de saída

3.2. Etapa 1: Carregamento e Pré-processamento dos Dados

Os textos brutos passaram por uma função de limpeza para padronização de caracteres, conversão para minúsculas e eliminação de ruídos numéricos/pontuações.

```
1 def limpar_texto(texto):
2     texto = texto.lower()
3     texto = re.sub(r'[^\w\s]', '', texto)
4     texto = re.sub(r'\d+', '', texto)
5     palavras = texto.split()
6     palavras = [
7         palavra for palavra in palavras
8         if palavra not in palavras_irrelevantes
9     ]
10    return " ".join(palavras)
```

Código 1: Função de limpeza textual e preparação do corpus

Saída esperada:

Shape original da base: (2225, 2)

Shape após limpeza: (2225, 2) - Sem NaNs observados.

3.3. Etapa 2: Construção da Matriz TF-IDF e Extração do Modelo NMF

Nesta etapa, o corpus limpo foi convertido à forma estruturada numérica e decomposto pelas funções nativas do scikit-learn.

```
1 from sklearn.feature_extraction.text import TfidfVectorizer
2 from sklearn.decomposition import NMF
3
4 # Construção da matriz TF-IDF
5 vectorizer = TfidfVectorizer(
6     max_df=0.95,
7     min_df=2,
8     max_features=2000,
9     stop_words=palavras_irrelevantes
```

```
10 )
11 V = vectorizer.fit_transform(corpus_limpo)
12
13 # Aplicação da Fatoração Matricial Não Negativa
14 n_topicos = 5
15 nmf_model = NMF(
16     n_components=n_topicos,
17     random_state=42,
18     init='nndsvd'
19 )
20 W = nmf_model.fit_transform(V)
21 H = nmf_model.components_
```

Código 2: Vetorização TF-IDF e Fatoração por NMF

A matriz **W** indica o grau de pertencimento de cada documento a cada tópico identificado, enquanto a matriz **H** contém os pesos das palavras em cada tópico.

Resultado

A fatoração convergiu com sucesso através do inicializador estável NNDSVD. A reconstrução apresentou erros residuais mínimos aceitáveis dentro das iterações delimitadas do algoritmo.

3.4. Etapa 3: Visualização e Avaliação das Palavras-Chave

Após a execução, foram selecionadas as sete palavras com maior peso em cada componente de **H**, associando os clusters gerados às editorias nativas do portal BBC News.

[Inserir gráfico de barras ou distribuição dos pesos dos tópicos obtidos via H]

Figura 1: Representação visual da relevância de termos por componentes latentes.

4. Conclusão

Os resultados demonstraram que a combinação entre TF-IDF e Fatoração Matricial Não Negativa foi capaz de identificar automaticamente estruturas temáticas presentes em uma coleção de notícias sem a utilização de rótulos supervisionados. A matriz TF-IDF forneceu uma representação eficiente dos documentos, enquanto o NMF revelou tópicos semanticamente interpretáveis através da decomposição aditiva.

Além da identificação dos tópicos principais, o sistema foi capaz de realizar a extração estável de palavras-chave altamente representativas para cada editoria da BBC News mapeada: *Business*, *Entertainment*, *Politics*, *Sport* e *Technology*. Isso evidencia a expressiva aplicabilidade de técnicas de Álgebra Linear Numérica em problemas modernos de Processamento de Linguagem Natural e Inteligência Computacional.