
Instituto Federal da Paraíba

Campus Campina Grande · Engenharia de Computação

Projeto 2 – Métodos Numéricos

Modelagem de Tópicos em Notícias Utilizando TF-IDF e Fatoração Matricial Não Negativa

Alunos: Guilherme José Mendes Jerônimo (202321250017)
William de Sousa Costa (202321250008)

Professor: Paulo Ribeiro

Semestre: 2025.1

Entrega: 22 de junho de 2026

Sumário

1	Descrição do Problema	2
1.1	Contexto e Motivação	2
1.2	Formulação Matemática	2
1.3	Aplicações Associadas	3
1.4	Método 1: TF-IDF	4
1.4.1	Descrição Geral	4
1.4.2	Formulação	4
1.5	Método 2: Fatoração Matricial Não Negativa (NMF)	4
1.5.1	Descrição Geral	4
1.5.2	Formulação	4
1.5.3	Complexidade	4
1.6	Ambiente e Dependências	5
2	Conclusão	7
2.1	Extração de Palavras-Chave	7
3	Referências	8

1. Descrição do Problema

1.1. Contexto e Motivação

O crescimento exponencial da quantidade de documentos digitais tornou inviável a classificação manual de grandes coleções textuais. Portais de notícias, redes sociais e repositórios corporativos produzem milhares de documentos diariamente, exigindo técnicas automáticas para organização e descoberta de conhecimento.

Uma das abordagens mais utilizadas para esse problema é a **Modelagem de Tópicos (Topic Modeling)**, cujo objetivo é identificar temas latentes presentes em um conjunto de documentos sem a necessidade de rótulos previamente definidos.

Neste projeto foi utilizada uma base de notícias da BBC News contendo documentos de diferentes áreas, como política, negócios, esportes, entretenimento e tecnologia. O objetivo consiste em descobrir automaticamente esses agrupamentos temáticos por meio de técnicas de Processamento de Linguagem Natural (PLN) e fatoração matricial.

1.2. Formulação Matemática

Após o pré-processamento textual, cada documento é convertido para uma representação numérica utilizando a técnica TF-IDF.

A matriz documento-termo é definida por

$$V \in \mathbb{R}^{m \times n}$$

onde:

- m representa o número de documentos;
- n representa o número de termos do vocabulário.

A modelagem de tópicos é realizada através da **Fatoração Matricial Não Negativa (NMF)**, que procura decompor a matriz original em duas matrizes menores:

$$V \approx WH \tag{1}$$

onde:

$$W \in \mathbb{R}^{m \times k}$$

representa a distribuição de tópicos em cada documento e

$$H \in \mathbb{R}^{k \times n}$$

representa a relevância de cada palavra para cada tópico.

O parâmetro k corresponde ao número de tópicos desejados.

1.3. Aplicações Associadas

A modelagem de tópicos possui diversas aplicações práticas:

- Organização automática de notícias;
- Sistemas de recomendação de conteúdo;
- Análise de tendências em redes sociais;
- Descoberta de conhecimento em bases documentais;
- Recuperação de informação.

Base de Dados

Foi utilizada uma coleção de notícias da BBC News contendo textos em língua inglesa. Os documentos foram submetidos a etapas de limpeza, remoção de stopwords e vetorização TF-IDF antes da aplicação do modelo NMF.

1.4. Método 1: TF-IDF

1.4.1. Descrição Geral

O algoritmo TF-IDF (Term Frequency – Inverse Document Frequency) transforma documentos textuais em vetores numéricos.

A frequência TF mede a importância de uma palavra dentro de um documento, enquanto o fator IDF reduz a relevância de palavras excessivamente comuns.

1.4.2. Formulação

$$TFIDF(t, d) = TF(t, d) \times IDF(t)$$

com

$$IDF(t) = \log \left(\frac{N}{df(t)} \right)$$

onde N é o número total de documentos e $df(t)$ é o número de documentos que contêm o termo t .

1.5. Método 2: Fatoração Matricial Não Negativa (NMF)

1.5.1. Descrição Geral

A Fatoração Matricial Não Negativa é uma técnica de decomposição de matrizes amplamente utilizada em mineração de textos (DataCamp, 2024).

Seu objetivo é aproximar a matriz documento-termo por duas matrizes não negativas menores, permitindo interpretar cada componente como um tópico latente (NBIS, 2024).

1.5.2. Formulação

$$V \approx WH$$

sujeito a

$$W \geq 0$$

$$H \geq 0$$

A restrição de não negatividade favorece a interpretabilidade dos resultados, permitindo que cada tópico seja representado por um conjunto de palavras com pesos positivos.

1.5.3. Complexidade

Propriedade	Valor
Complexidade Temporal	$\mathcal{O}(mnk)$ por iteração
Complexidade Espacial	$\mathcal{O}(mk + kn)$
Convergência	Iterativa

1.6. Ambiente e Dependências

A implementação foi desenvolvida em Python utilizando:

- pandas
- numpy
- nltk
- scikit-learn
- matplotlib

```
1 def limpar_texto(texto):
2     texto = texto.lower()
3     texto = re.sub(r'[\w\s]', '', texto)
4     texto = re.sub(r'\d+', '', texto)
5
6     palavras = texto.split()
7
8     palavras = [
9         palavra for palavra in palavras
10        if palavra not in palavras_irrelevantes
11    ]
12
13    return " ".join(palavras)
```

Listing 1: Função de limpeza textual

```
1 vectorizer = TfidfVectorizer(
2     max_df=0.95,
3     min_df=2,
4     max_features=2000,
5     stop_words=palavras_irrelevantes
6 )
7
8 V = vectorizer.fit_transform(corpus_limpo)
```

Listing 2: Construção da matriz TF-IDF

```
1 n_topicos = 5
2
3 nmf_model = NMF(
4     n_components=n_topicos,
5     random_state=42,
6     init='nndsvd'
7 )
8
9 W = nmf_model.fit_transform(V)
10 H = nmf_model.components_
```

Listing 3: Aplicação da Fatoração Matricial Não Negativa

A matriz W indica o grau de pertencimento de cada documento a cada tópico identificado.

Já a matriz H contém os pesos das palavras em cada tópico, permitindo descobrir automaticamente os termos mais representativos de cada categoria.

2. Conclusão

Os resultados demonstraram que a combinação entre TF-IDF e Fatoração Matricial Não Negativa foi capaz de identificar automaticamente estruturas temáticas presentes em uma coleção de notícias sem a utilização de rótulos supervisionados.

A matriz TF-IDF forneceu uma representação eficiente dos documentos, enquanto o NMF revelou tópicos semanticamente interpretáveis através da decomposição da matriz documento-termo.

Além da identificação dos tópicos principais, o sistema foi capaz de:

- Extrair palavras-chave representativas;
- Identificar documentos protótipos de cada categoria;
- Detectar textos híbridos contendo múltiplos assuntos;
- Classificar documentos inéditos.

Esses resultados evidenciam a aplicabilidade de técnicas de Álgebra Linear e Métodos Numéricos em problemas modernos de Processamento de Linguagem Natural e Mineração de Textos.

2.1. Extração de Palavras-Chave

Após a decomposição NMF, foram selecionadas as sete palavras com maior peso em cada tópico.

Essas palavras permitiram identificar categorias equivalentes às editorias da BBC News:

- Business
- Entertainment
- Politics
- Sport
- Technology

3. Referências

DATA CAMP. *What is Topic Modeling? A Guide With Examples*. 2024. Disponível em: <https://www.datacamp.com/tutorial/what-is-topic-modeling>. Acesso em: 12 jun. 2026.

NBIS. *Non-negative Matrix Factorization (NMF)*. 2024. Disponível em: https://nbisweden.github.io/workshop_omics_integration/session_nmf/NMF_main.html. Acesso em: 12 jun. 2026.